Sentimiento en noticias financieras y movimiento de precios

Informe técnico del Trabajo Práctico Integrador

Procesamiento de Lenguaje Natural

Universidad de Palermo

Profesor Nicolás Rubinstein

Grupo 10

Gastón Eduardo Echegoyen

Joaquín Rodriguez

Simón Martín Rubiño Montilla

Juan Pablo García Guerrero

Noviembre de 2026

Resumen

Clasificamos el sentimiento de titulares de noticias financieras sobre ocho acciones muy negociadas y analizamos si esa señal de texto se relaciona con el movimiento del precio en la ventana siguiente a la publicación. El precio se usa solo como referencia para evaluar y no forma parte de ningún modelo. No hicimos etiquetado manual. Los modelos se entrenaron y evaluaron con dos datasets públicos (Financial PhraseBank y Twitter Financial News Sentiment), y las noticias reales se evaluaron contra el precio.

Comparamos un baseline de TF-IDF con regresión logística y SVM lineal contra embeddings de oraciones con regresión logística, FinBERT sin reentrenar y un LLM sin ajuste (Gemini, en zero-shot y few-shot). En el test de Twitter, el más parecido a los titulares reales, el baseline obtiene el mejor F1 macro (0,77) y supera con diferencias significativas a FinBERT y a Gemini. En PhraseBank ganan los embeddings (0,90). El efecto más fuerte es el del cambio de dominio, ya que TF-IDF entrenado solo con PhraseBank cae a 0,44 en Twitter, mientras que los embeddings se sostienen en 0,67.

Sobre 9.079 titulares reales, el sentimiento predicho se relaciona con fuerza con el retorno anormal del mismo día (los titulares positivos tienen entre 122 y 154 puntos básicos más que los negativos) y también con el del día anterior. En la ventana siguiente no aparece ninguna relación positiva con ninguno de los cinco modelos. Los titulares cuentan lo que el precio ya hizo, pero no lo anticipan.

1. Introducción

Las noticias financieras son una de las fuentes de información más seguidas por los inversores, y la idea de convertir ese texto en una señal cuantitativa es antigua (Tetlock, 2007). El problema tiene dos partes. La primera es de procesamiento de lenguaje y consiste en clasificar automáticamente si una noticia es buena, mala o neutra para un activo. La segunda es financiera y consiste en ver si esa clasificación dice algo sobre lo que va a pasar con el precio.

En la propuesta que presentamos acotamos el trabajo a la primera parte. Los modelos solo clasifican texto, y el precio aparece únicamente como referencia para evaluar la señal resultante, sin entrar como variable en ningún modelo. La comparación central del trabajo es entre un baseline clásico de TF-IDF con un clasificador lineal y versiones con embeddings o con un LLM. Agregamos FinBERT porque es el modelo de referencia en sentimiento financiero.

Las preguntas que guían el trabajo son tres.

1. ¿Qué tan bien clasifican el sentimiento financiero los distintos enfoques, y cuál conviene?
2. ¿Qué pasa cuando el texto que hay que clasificar tiene un estilo distinto al de entrenamiento?
3. ¿La señal de sentimiento de los titulares reales se relaciona con el movimiento del precio en la ventana siguiente?

Todo el trabajo está en una sola notebook de Google Colab, con el código, las salidas y la lectura de cada resultado. Este informe resume el diseño, los resultados y las conclusiones.

2. Datos

2.1 Datos etiquetados

Usamos dos datasets públicos de sentimiento financiero en inglés con tres clases, que unificamos como positivo, negativo y neutro.

- **Financial PhraseBank** (Malo et al., 2014). Son oraciones de noticias sobre empresas que cotizan en Helsinki, etiquetadas por 16 personas con formación en finanzas. Usamos el subconjunto en el que al menos el 75 % de los anotadores coincidió, que tiene 3.453 oraciones.
- **Twitter Financial News Sentiment** (dataset zeroshot de Hugging Face). Son 11.931 titulares y tuits de cuentas de noticias de mercado de 2019 y 2020, etiquetados como Bearish (negativo), Bullish (positivo) o Neutral.

Las dos fuentes tienen una distribución de clases parecida, con neutro como mayoría (62 % y 65 %) y negativo como la clase más chica (12 % y 15 %). Se diferencian en el estilo. Las oraciones de PhraseBank tienen 23 palabras en promedio y redacción formal, con cifras y monedas, y los tuits tienen 12 palabras en promedio, cashtags y abreviaturas. Esa diferencia es la que usamos para estudiar el cambio de dominio.

De los tuits sacamos los links acortados. No hicimos otro preprocesamiento porque palabras como not, up o down, que una lista de stop-words eliminaría, son centrales para el sentimiento. Twitter trae una partición de validación, que usamos como test, y del resto separamos un 15 % como dev para elegir hiperparámetros. En PhraseBank armamos la partición con un 15 % para test y un 15 % del resto para dev, estratificando por clase. Por último normalizamos los textos y sacamos de train y dev los 42 que también estaban en algún test, para evitar fuga de información. La Tabla 1 resume el resultado.

Tabla 1. Textos por fuente y partición, después de quitar duplicados y fugas.

Fuente	Train	Dev	Test	Total
Financial PhraseBank	2.490	440	518	3.448
Twitter Financial News	7.960	1.407	2.372	11.739
Total	10.450	1.847	2.890	15.187

2.2 Noticias reales y precios

Elegimos ocho acciones muy negociadas y con mucha cobertura de prensa (Apple, Microsoft, Nvidia, Tesla, Amazon, Meta, Alphabet y JPMorgan) y juntamos los titulares en inglés de los 90 días previos al 30 de octubre de 2026 desde el buscador RSS de Google News. Como cada consulta devuelve hasta 100 resultados, buscamos semana por semana, una vez por el nombre de la empresa y otra por el ticker.

Después nos quedamos con los titulares de 5 a 30 palabras que nombran a la empresa o a su ticker y eliminamos los repetidos entre medios, conservando la primera publicación. También marcamos con una expresión regular los titulares que describen un movimiento de precio, como "Tesla shares fall 5%", porque su relación con el precio del mismo día es casi tautológica y conviene analizarlos por separado. La Tabla 2 muestra cada paso de la limpieza.

Tabla 2. Titulares en cada paso de la limpieza.

Paso	Titulares
Titulares crudos	13.566
Con 5 a 30 palabras	13.499
Que nombran a la empresa o al ticker	12.818
Sin repetidos	9.079
Que además describen un movimiento de precio	22 %

Quedaron entre 981 titulares (JPMorgan) y 1.306 (Tesla) por acción. Los precios son cierres diarios ajustados de Yahoo Finance para las ocho acciones y para SPY, el ETF del S&P 500, entre el 21 de julio y el 30 de octubre de 2026 (73 ruedas).

3. Metodología

3.1 Modelos

- **TF-IDF con regresión logística o SVM lineal.** Es el baseline. Cada texto se representa con TF-IDF de palabras y bigramas, más n-gramas de caracteres de 2 a 5, con frecuencia sublineal. Los dos clasificadores usan pesos balanceados por clase, y el hiperparámetro C se elige en dev dentro de la grilla 0,1, 0,3, 1, 3 y 10.
- **Embeddings con regresión logística.** Usamos all-mpnet-base-v2 (Reimers y Gurevych, 2019), un modelo de embeddings de oraciones general y congelado, como extractor de features, y encima entrenamos la misma regresión logística.
- **FinBERT.** Es ProsusAI/finbert (Araci, 2019), un BERT ajustado para sentimiento financiero, usado sin reentrenar. Como se ajustó con Financial PhraseBank, su resultado en ese test no mide generalización y solo lo reportamos como referencia.
- **Gemini sin ajuste.** Usamos gemini-3.5-flash-lite en zero-shot, con instrucciones que definen cada clase, y en few-shot, con nueve ejemplos de train (tres por clase). Los textos se mandan en lotes de 25 con salida JSON estructurada. Elegimos el modelo Flash-Lite porque el plan gratuito permite 20 consultas diarias para los Flash completos y 500 para Flash-Lite, y el trabajo necesitaba unas 150. Por ese mismo límite, Gemini clasifica una muestra fija de hasta 600 textos por test, estratificada por clase. Todas las respuestas quedan guardadas, lo que hace reproducibles los resultados.

Los modelos entrenables se entrenan en tres regímenes, con las dos fuentes juntas o con una sola. El modelo entrenado con las dos fuentes es el que después clasifica las noticias reales, y los de una sola fuente sirven para medir el efecto del cambio de dominio.

3.2 Evaluación contra etiquetas

La métrica principal es el F1 macro, que promedia el F1 de las tres clases con el mismo peso y por eso no premia a un modelo que solo acierta la clase mayoritaria. Cada F1 se acompaña de un intervalo de confianza del 95 % por bootstrap con 1.000 remuestreos de los textos del test. Para decidir si dos modelos difieren de verdad usamos un bootstrap pareado, que remuestrea los mismos textos para los dos modelos y calcula el intervalo de la diferencia. Para comparar a todos los modelos en igualdad de condiciones, los evaluamos sobre la misma muestra que clasificó Gemini.

3.3 Evaluación contra el precio

Para cada titular definimos el día del evento como la primera rueda cuyo cierre ocurre después de la publicación. La bolsa de Nueva York cierra a las 16:00, así que una noticia publicada después de esa hora o en un fin de semana se asigna a la rueda siguiente. Con los cierres calculamos el retorno en tres ventanas, que son la previa (del cierre de dos días antes al del día anterior), la del evento (del cierre del día anterior al del día del evento) y la siguiente (del cierre del día del evento al del día posterior). La ventana siguiente es la que pide la pregunta del trabajo, porque es la única que empieza después de publicada la noticia.

Usamos el retorno anormal, que es el retorno de la acción menos el de SPY en la misma ventana, para no atribuirle a una noticia un movimiento de todo el mercado. La relación entre señal y precio se mide de tres maneras.

1. Por titular, con la diferencia entre el retorno anormal medio de los titulares positivos y el de los negativos, con intervalo por bootstrap.
2. Por acción y día, con la correlación de Spearman entre un puntaje diario (el promedio de +1, 0 y −1 de los titulares de esa acción en ese día) y el retorno anormal. Agrupamos por día porque varios titulares del mismo día comparten el retorno y no son observaciones independientes.
3. Por dirección, con la proporción de días con puntaje distinto de cero en los que el signo del puntaje coincide con el del retorno, comparada con el 50 % mediante una prueba binomial.

Cada análisis se repite con todos los titulares, sin los que describen el precio y solo con estos últimos.

4. Resultados

4.1 Clasificación

La Tabla 3 compara a todos los modelos sobre los mismos textos. En PhraseBank la muestra coincide con el test completo, y en Twitter es una muestra estratificada de 600 tuits.

Tabla 3. F1 macro sobre la muestra común, con intervalo de confianza del 95 % por bootstrap. El asterisco marca el resultado de FinBERT en el dataset con el que fue ajustado.

Modelo	PhraseBank (518)	IC 95 %	Twitter (600)	IC 95 %
TF-IDF + reg. logística	0,835	0,793 a 0,871	0,772	0,729 a 0,810
TF-IDF + SVM lineal	0,842	0,803 a 0,877	0,771	0,725 a 0,811
Embeddings + reg. logística	0,897	0,866 a 0,924	0,739	0,700 a 0,779
FinBERT	0,933 *	0,907 a 0,955	0,672	0,631 a 0,713
Gemini zero-shot	0,846	0,814 a 0,876	0,682	0,642 a 0,720
Gemini few-shot	0,883	0,854 a 0,911	0,671	0,631 a 0,710

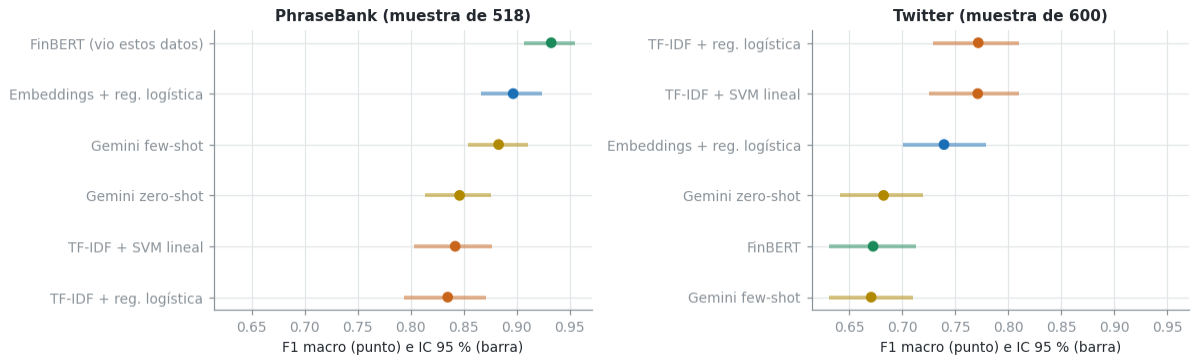


Figura 1. F1 macro e intervalo del 95 % de cada modelo sobre la muestra común.

En Twitter el baseline de TF-IDF queda primero. Según el bootstrap pareado (Tabla 4), supera a Gemini few-shot y a FinBERT por unos 10 puntos, con intervalos que no incluyen al cero. La diferencia con los embeddings no es significativa, y tampoco la que hay entre Gemini few-shot y zero-shot. En PhraseBank, dejando de lado a FinBERT, ganan los embeddings, seguidos por Gemini few-shot, con intervalos que se superponen. En PhraseBank el few-shot mejora al zero-shot de 0,846 a 0,883, mientras que en Twitter no lo mejora.

Tabla 4. Diferencias de F1 macro en la muestra de Twitter según el bootstrap pareado.

Comparación	Diferencia	IC 95 %
Gemini few-shot menos TF-IDF + reg. logística	−0,101	−0,150 a −0,050
FinBERT menos TF-IDF + reg. logística	−0,099	−0,148 a −0,052
Embeddings menos TF-IDF + reg. logística	−0,032	−0,076 a 0,015
Gemini few-shot menos Gemini zero-shot	−0,012	−0,033 a 0,009
Gemini few-shot menos FinBERT	−0,002	−0,046 a 0,047

Las palabras con más peso en la regresión logística tienen sentido financiero. En positivo aparecen up, rises, beats on, raised y tops, y en negativo down, misses, target cut, downgraded y weighs on. La clase neutra se aprende sobre todo como ausencia de esas palabras e incluye términos como trump, una correlación espuria que refleja la época del dataset de Twitter.

El costo de inferencia es muy distinto entre modelos. TF-IDF clasifica 1.000 textos en menos de un segundo en CPU, FinBERT tarda entre 2 y 5 segundos con GPU y Gemini unos 62 segundos, por la demora de la API.

4.2 Cambio de dominio

La Tabla 5 muestra el F1 macro en cada test según la fuente de entrenamiento. Es el resultado más marcado de la parte de clasificación.

Tabla 5. F1 macro en el test completo según la fuente de entrenamiento.

Modelo	Entrenamiento	PhraseBank	Twitter
TF-IDF + reg. logística	Las dos fuentes	0,835	0,760
	Solo PhraseBank	0,828	0,443
	Solo Twitter	0,604	0,759
TF-IDF + SVM lineal	Las dos fuentes	0,842	0,768
	Solo PhraseBank	0,821	0,456
	Solo Twitter	0,584	0,762
Embeddings + reg. logística	Las dos fuentes	0,897	0,760
	Solo PhraseBank	0,911	0,671
	Solo Twitter	0,828	0,771
FinBERT	Ajustado con PhraseBank	0,933 *	0,659

TF-IDF depende del vocabulario exacto que vio en entrenamiento. Entrenado solo con PhraseBank cae a 0,44 en Twitter, y entrenado solo con Twitter cae a 0,60 en PhraseBank. Los embeddings, en cambio, conservan buena parte del desempeño (0,67 y 0,83), porque la representación preentrenada acerca palabras y frases de significado parecido aunque no hayan aparecido en train. FinBERT, que en la práctica es un modelo ajustado solo con PhraseBank, obtiene en Twitter casi lo mismo que los embeddings entrenados solo con PhraseBank. Entrenar con las dos fuentes recupera en cada test el desempeño del entrenamiento con esa sola fuente, por eso es la versión que aplicamos a las noticias reales.

4.3 Errores del LLM

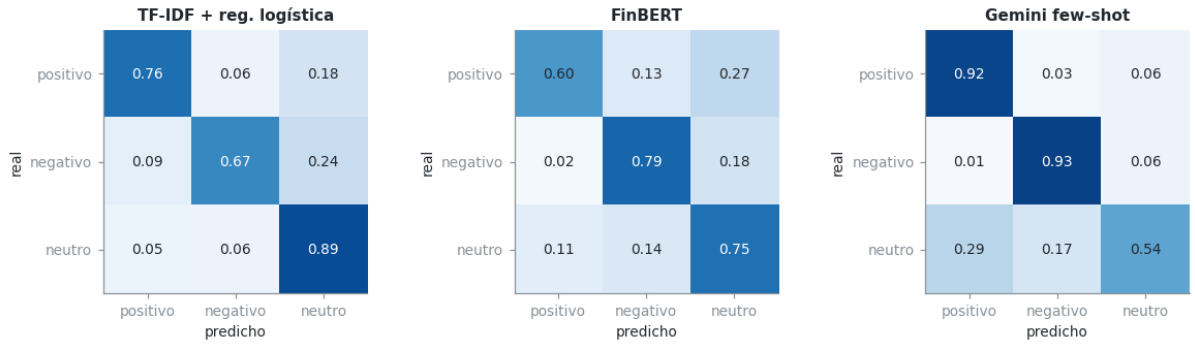


Figura 2. Matrices de confusión normalizadas por fila en la muestra de Twitter.

Gemini es el modelo que mejor detecta positivos (92 %) y negativos (93 %) en Twitter, pero solo clasifica como neutros al 54 % de los textos neutros y al 29 % los llama positivos. Los casos de desacuerdo explican el motivo. Textos como "Chubb to buy stake in China's Huatai Insurance for $1.53 billion" o "AltaGas declares CAD 0.08 dividend" están etiquetados como neutros en el dataset, y Gemini los clasifica como positivos. Nuestro prompt define los acuerdos comerciales como noticias positivas, mientras que los anotadores de Twitter marcaron las compras y los dividendos como neutros. Los modelos supervisados aprenden esa convención a partir de unos 8.000 ejemplos, pero nueve ejemplos en el prompt no alcanzan para transmitirla. Parte del error de Gemini es entonces un desacuerdo con el criterio de etiquetado, más que una falla de comprensión.

4.4 Clasificación de las noticias reales

Aplicamos los modelos entrenados con las dos fuentes y FinBERT a los 9.079 titulares, y Gemini zero-shot a una muestra de 1.500 estratificada por acción, indicándole de qué acción habla cada titular. La Tabla 6 muestra cómo se reparten las clases predichas.

Tabla 6. Distribución de las clases predichas en los titulares reales.

Modelo	Positivo	Negativo	Neutro
TF-IDF + reg. logística	30 %	18 %	51 %
TF-IDF + SVM lineal	29 %	17 %	54 %
Embeddings + reg. logística	35 %	26 %	39 %
FinBERT	23 %	23 %	54 %
Gemini zero-shot (1.500 titulares)	45 %	22 %	33 %

Como estos titulares no tienen etiqueta, medimos el acuerdo entre modelos con el kappa de Cohen. Los dos TF-IDF coinciden casi siempre ($\kappa = 0{,}90$) porque comparten la representación, pero entre familias distintas el acuerdo es moderado, con valores entre 0,33 y 0,50. Ningún modelo se entrenó con titulares de 2026 y cada uno generaliza de manera diferente, así que la elección del modelo cambia la señal que se obtiene.

4.5 Relación entre la señal y el precio

La Tabla 7 resume la relación con el retorno anormal para todos los titulares y la Figura 3 muestra el retorno medio por clase predicha en tres de los modelos.

Tabla 7. Relación entre la señal y el retorno anormal, con todos los titulares. La diferencia y su intervalo están en puntos básicos (pb).

Modelo	Ventana	Positivos menos negativos	IC 95 %	Spearman	Acierto
TF-IDF + reg. log.	previa	55	40 a 69	0,17	55 %
	evento	142	126 a 159	0,36	60 %
	siguiente	−15	−25 a −4	−0,04	49 %
TF-IDF + SVM	previa	61	45 a 77	0,18	53 %
	evento	154	136 a 172	0,37	60 %
	siguiente	−17	−29 a −6	−0,06	49 %
Embeddings	previa	65	52 a 77	0,22	59 %
	evento	139	123 a 155	0,44	64 %
	siguiente	−20	−29 a −11	−0,13	44 %
FinBERT	previa	75	60 a 88	0,25	60 %
	evento	122	106 a 138	0,35	63 %
	siguiente	−18	−29 a −7	−0,10	46 %
Gemini zero-shot	previa	61	25 a 96	0,14	55 %
	evento	133	101 a 170	0,28	61 %
	siguiente	0	−24 a 25	0,02	48 %

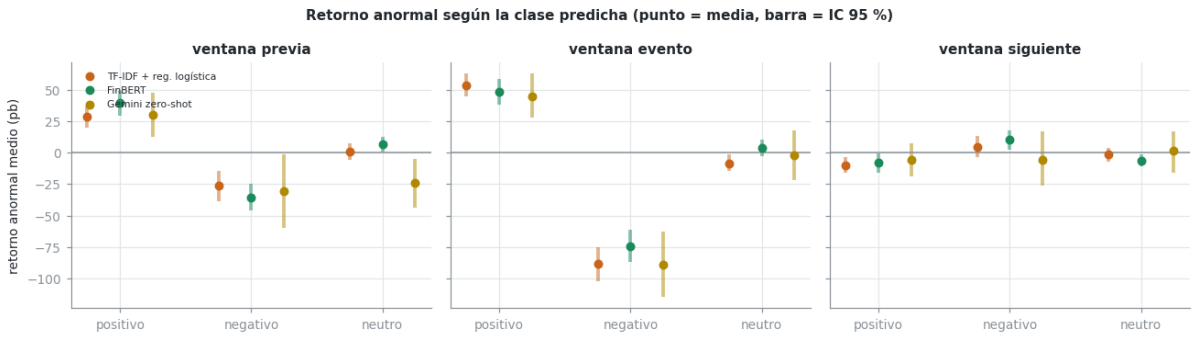


Figura 3. Retorno anormal medio según la clase predicha en cada ventana. El punto es la media y la barra el intervalo del 95 %.

El patrón se repite en los cinco modelos. En la ventana del evento la relación es fuerte. Los titulares positivos tienen un retorno anormal entre 122 y 154 pb mayor que los negativos, la correlación del puntaje diario va de 0,28 a 0,44 y el signo se acierta entre el 60 % y el 64 % de los días, con $p < 0{,}001$ en todos los casos. En la ventana previa también hay relación, porque muchos titulares se escriben después de que el precio se movió. En la ventana siguiente no hay relación positiva. La diferencia es levemente negativa, de 15 a 20 pb en cuatro modelos, y el acierto de dirección no supera el 49 %.

Sin los titulares que describen el precio, la relación en la ventana del evento cae a la mitad (en TF-IDF pasa de 142 a 67 pb) pero sigue siendo significativa. En la ventana siguiente, el intervalo de la diferencia incluye al cero en cuatro de los cinco modelos y el acierto queda entre 46 % y 50 % (Tabla 8).

Con solo los titulares de precio, la ventana del evento alcanza entre 226 y 286 pb de diferencia y entre 65 % y 69 % de acierto, como era de esperar.

Tabla 8. Ventana siguiente, sin los titulares que describen el precio.

Modelo	Positivos menos negativos (pb)	IC 95 %	Spearman	Acierto
TF-IDF + reg. logística	−6	−20 a 6	−0,01	50 %
TF-IDF + SVM lineal	−11	−23 a 2	−0,04	49 %
Embeddings + reg. logística	−17	−27 a −6	−0,10	46 %
FinBERT	−10	−23 a 3	−0,07	47 %
Gemini zero-shot	7	−22 a 36	0,02	49 %

5. Discusión

El primer resultado es que el baseline clásico no es fácil de superar cuando hay muchos datos etiquetados del mismo estilo que el texto a clasificar. Con unos 8.000 tuits de entrenamiento, TF-IDF aprende tanto el vocabulario del sentimiento como la convención de etiquetado del dataset, y eso le alcanza para superar a modelos mucho más grandes y costosos. La ventaja de los modelos preentrenados aparece cuando cambia el dominio. Ahí los embeddings y FinBERT conservan buena parte del desempeño y TF-IDF no. El LLM ocupa un lugar intermedio, porque no necesita datos de entrenamiento pero aplica la definición de la tarea que le damos en el prompt, que puede no coincidir con la de quienes etiquetaron el dataset.

Esto importa para las noticias reales, que son un tercer dominio, distinto de los dos datasets. El acuerdo moderado entre modelos sobre esos titulares muestra que la incertidumbre de la clasificación es mayor de lo que sugieren los tests etiquetados, y es la razón por la que usamos el precio como referencia para evaluar.

En cuanto al precio, todos los modelos coinciden en que el sentimiento de los titulares acompaña y sigue al movimiento, pero no lo anticipa. La relación con la ventana previa indica que muchas noticias se escriben como reacción a un movimiento ya ocurrido. La relación del mismo día no permite separar causa y efecto, porque la noticia pudo mover el precio o el precio pudo motivar la nota. La leve reversión del día siguiente es consistente con lo que encontró Tetlock (2007), aunque es un efecto chico (de 15 a 20 pb frente a un desvío diario de 173 pb) y no se sostiene en la mayoría de los modelos cuando se excluyen los titulares de precio. Para acciones tan seguidas por el mercado como estas, la información de los titulares parece estar ya en el precio cuando se publica la noticia.

Hay que tener en cuenta que hicimos 45 comparaciones entre modelos, ventanas y grupos de titulares. Con un nivel del 5 %, algunos resultados aislados pueden salir significativos por azar. Por eso le damos más peso a la consistencia del patrón entre modelos que a cualquier valor p individual.

6. Limitaciones

- **Hora de publicación.** Para muchos titulares Google News informa solo la fecha, con hora 07:00 UTC. Si alguno se publicó después del cierre, lo asignamos al día anterior al correcto, y su reacción caería en nuestra ventana siguiente, lo que empujaría a encontrar una relación positiva

ahí que no aparece. Con datos diarios, además, no se puede separar lo que pasó antes y después de la noticia dentro del mismo día.

- **Asignación de titulares.** Que un titular nombre a una empresa no garantiza que hable de ella. Por ejemplo, "Ather Energy Stock Climbs Nearly 4% On JPMorgan Target Hike" quedó asignado a JPMorgan.
- **Alcance.** Son ocho acciones muy grandes durante 90 días, unos 510 pares de acción y día. En empresas más chicas y con menos cobertura el resultado podría ser distinto.
- **Etiquetas de otro dominio.** Los datasets son de otras épocas y estilos y tienen sus propias convenciones de etiquetado. Como decidimos no etiquetar a mano, no podemos medir la exactitud de los modelos sobre los titulares de 2026.
- **LLM.** Por el límite del plan gratuito usamos un modelo liviano y muestras de 600 y 1.500 textos. Un modelo más grande, o un prompt que siga la convención de Twitter, podría rendir distinto.
- **Sentimiento e impacto.** Tres clases no distinguen una noticia levemente buena de una muy buena, ni miden cuánto sorprende la noticia respecto de lo que el mercado esperaba.
- **Hiperparámetros.** En la regresión logística el valor de C elegido quedó en el extremo de la grilla.

7. Conclusiones

Es posible clasificar el sentimiento de noticias financieras sin etiquetado manual, a partir de datasets públicos, con un F1 macro de 0,77 en tuits de mercado y cercano a 0,90 en oraciones de noticias. Ningún enfoque es el mejor en todos los casos. Dentro de un dominio con muchos datos etiquetados, el baseline de TF-IDF es tan bueno o mejor que los modelos más grandes y es mucho más barato. Cuando cambia el dominio, las representaciones preentrenadas son claramente más robustas. El LLM sin ajuste da resultados competitivos en PhraseBank, pero sigue la definición de la tarea que le damos y no la convención de cada dataset.

Sobre la pregunta principal, la señal de texto se relaciona fuertemente con el precio del mismo día y del día anterior y no con el de la ventana siguiente, en ninguno de los cinco modelos. Para estas acciones, los titulares describen el movimiento del precio pero no lo anticipan. Como extensiones naturales quedan usar precios intradiarios y la hora exacta de publicación, ampliar el análisis a empresas con menos cobertura y ajustar un modelo con una pequeña muestra de titulares del dominio real.

8. Reproducibilidad

El repositorio contiene la notebook TP_Integrador_Grupo10.ipynb, ya ejecutada, con todo el código, las salidas y la lectura de cada resultado. Se corre en Google Colab con una GPU T4, la carpeta del proyecto en Google Drive y una clave de la API de Gemini. Los datos descargados, los titulares, los precios y las respuestas del LLM quedan guardados en las carpetas data y resultados, así que una nueva ejecución reproduce los mismos números sin volver a consultar las fuentes.

Referencias

Araci, D. (2019). FinBERT: Financial sentiment analysis with pre-trained language models. arXiv:1908.10063.

Brown, T., Mann, B., Ryder, N. et al. (2020). Language models are few-shot learners. Advances in Neural Information Processing Systems 33.

Malo, P., Sinha, A., Korhonen, P., Wallenius, J. y Takala, P. (2014). Good debt or bad debt: Detecting semantic orientations in economic texts. Journal of the Association for Information Science and Technology, 65(4), 782-796.

Reimers, N. y Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. Proceedings of EMNLP-IJCNLP 2019.

Tetlock, P. C. (2007). Giving content to investor sentiment: The role of media in the stock market. The Journal of Finance, 62(3), 1139-1168.

Twitter Financial News Sentiment. Hugging Face, dataset zeroshot/twitter-financial-news-sentiment.

Google. Documentación de modelos y límites de la API de Gemini. ai.google.dev/gemini-api/docs/models.